Implementación de Regresión Logística con PyTorch

Clasificación de Calidad de Vino Tinto

1st Victor Aymerich
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
vaymerich@estudiantec.cr

2nd Alberto Alvarez
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
albalvarez@estudiantec.cr

3rd Alfredo Mercado
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
amercado@estudiantec.cr

***Abstract*—Este trabajo presenta el diseño, implementación y evaluación de un modelo de regresión logística construido con PyTorch para clasificar la calidad de vinos tintos como *BUENA* o *MALA*. Se realizó un análisis exploratorio exhaustivo sobre 1,143 instancias, incluyendo detección y corrección de valores atípicos mediante winzorización calculada exclusivamente sobre el conjunto de entrenamiento. La selección de las seis características más relevantes se fundamentó matemáticamente combinando correlación de Pearson e información mutua, también calculadas sobre entrenamiento para evitar *data leakage*. El conjunto de datos fue dividido de forma estratificada en entrenamiento (70%), validación (15%) y prueba (15%). Se ejecutaron diez experimentos con distintas combinaciones de *learning rate*, *batch size* y *epochs*. El modelo final, correspondiente al Experimento 9 (LR = 0.0005, batch = 32, epochs = 200), alcanzó un AUC de 0.8277 y un F1-Score de 0.7650 sobre el conjunto de prueba, sin evidencia de sobreajuste.**

***Index Terms*—regresión logística, PyTorch, clasificación binaria, calidad de vino, análisis exploratorio, selección de características, binary cross-entropy**

I. Introducción

La evaluación de la calidad del vino es una tarea que recae tradicionalmente en expertos mediante catas sensoriales, proceso costoso, subjetivo y difícil de escalar. El uso de modelos de aprendizaje automático entrenados sobre propiedades físico-químicas medibles constituye una alternativa objetiva y reproducible que ha ganado relevancia en la industria vitivinícola [3].

El *dataset* utilizado, obtenido de Kaggle [7], contiene 1,143 registros de vinos tintos con 11 características físico-químicas y una variable de calidad con valores enteros del 3 al 8. El objetivo de esta tarea es construir un clasificador binario que determine si un vino posee calidad *BUENA* o *MALA*, utilizando regresión logística implementada desde cero en PyTorch [1].

La regresión logística es un modelo lineal generalizado apropiado para clasificación binaria. Su función sigmoide produce probabilidades interpretables, sus pesos son directamente relacionables con la influencia de cada variable, y su implementación en PyTorch permite extender el código fácilmente a arquitecturas más complejas. Estas características la hacen una elección idónea como punto de partida para este problema.

II. Análisis Exploratorio de Datos

A. Descripción del Dataset

El conjunto de datos no presenta valores nulos en ninguna de sus variables, lo que elimina la necesidad de imputación. Las 11 variables predictoras son continuas de tipo `float64` y la variable `quality` es entera. La Tabla I resume las estadísticas descriptivas de las variables más relevantes.

TABLE I: Estadísticas descriptivas de variables principales

Variable	Media	Std	Mín	Máx
fixed acidity	8.311	1.748	4.60	15.90
volatile acidity	0.531	0.180	0.12	1.58
citric acid	0.268	0.197	0.00	1.00
chlorides	0.087	0.047	0.01	0.61
total sulfur dioxide	45.91	32.78	6.00	289.0
density	0.9967	0.002	0.990	1.004
sulphates	0.658	0.170	0.33	2.00
alcohol	10.442	1.082	8.40	14.90

B. Variable Objetivo

La variable `quality` fue binarizada según el criterio:

$$\text{target} = \begin{cases} 1 \text{ (BUENA)} & \text{si } \texttt{quality} \geq 6 \\ 0 \text{ (MALA)} & \text{si } \texttt{quality} < 6 \end{cases} \tag{1}$$

Como se aprecia en la Fig. 1, la distribución resultante es de 621 vinos BUENOS (54.33%) y 522 MALOS (45.67%). El dataset presenta un desbalance leve que, si bien no es crítico, justifica el uso de *stratified sampling* para preservar esta proporción en todos los subconjuntos y el uso del AUC como métrica principal de selección de modelo.

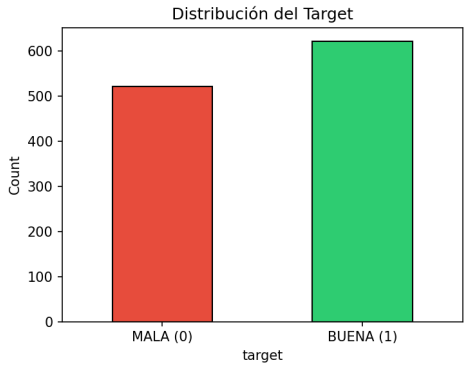

Fig. 1: Distribución de la variable objetivo binarizada. La clase BUENA (1) representa el 54.33% y MALA (0) el 45.67% del total.

C. Distribución de Variables Numéricas

Los histogramas de la Fig. 2 revelan patrones importantes en la distribución de las once variables. `residual sugar` y `chlorides` exhiben distribuciones fuertemente asimétricas hacia la derecha con una cola extensa, concentrando la gran mayoría de observaciones en valores bajos (2–3 g/L y 0.07–0.09 g/L respectivamente) pero con casos aislados que alcanzan 15.5 g/L y 0.6 g/L. `total sulfur dioxide` presenta un comportamiento similar con un rango de 6 a 289 mg/L. Por su parte, `pH` y `density` muestran distribuciones aproximadamente normales, centradas en 3.31 y 0.9967 respectivamente. `alcohol` muestra una distribución bimodal con picos alrededor de 9.5% y 11%, lo que anticipa su utilidad discriminativa. Estas asimetrías son indicativas de la presencia de valores atípicos que deben ser tratados antes del modelado.

D. Boxplots por Clase

Los boxplots estratificados por clase (Fig. 3) permiten identificar las variables con mayor poder discriminativo. `alcohol` muestra la diferencia más clara: la mediana de vinos BUENOS (11%) es notablemente superior a la de MALOS (9.5%), con rangos intercuartiles que apenas se solapan. `sulphates` evidencia una tendencia similar, con vinos BUENOS presentando valores más altos (0.70 vs. 0.62 g/L). `volatile acidity` muestra el patrón inverso: los vinos MALOS tienen mayor acidez volátil (mediana 0.58 vs. 0.49 g/L), consistente con que el exceso de ácido acético deteriora el sabor. En contraste, variables como `residual sugar`, `fixed acidity` y `pH` presentan cajas prácticamente superpuestas entre clases, lo que anticipa su menor contribución al modelo.

E. Matriz de Correlación

El mapa de calor (Fig. 4) revela la estructura de dependencias lineales del dataset. Respecto al *target*, `alcohol` lidera con la mayor correlación positiva (0.44), seguido de `sulphates` (0.23) y `citric acid` (0.16). `volatile acidity` presenta la correlación negativa más fuerte (-0.33), indicando que a mayor acidez volátil, menor probabilidad de calidad BUENA. Entre variables predictoras, se destaca la correlación entre `density` y `fixed acidity` (0.68), entre `citric acid` y `fixed acidity` (0.67), y entre `free sulfur dioxide` y `total sulfur dioxide` (0.66). Estas relaciones son relevantes para el análisis de multicolinealidad en la selección de características. Notablemente, `alcohol` y `density` presentan correlación inversa fuerte (-0.49), lo cual es esperado desde la química del vino: a mayor contenido alcóholico, menor densidad.

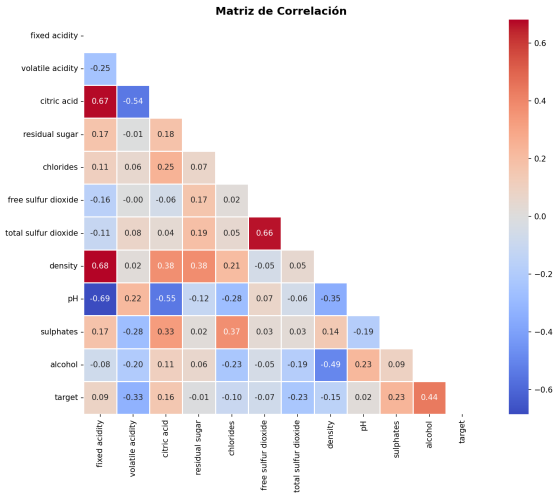

Fig. 4: Matriz de correlación de Pearson. La fila *target* muestra que `alcohol` (0.44) y `volatile acidity` (-0.33) son los predictores lineales más fuertes. Se identifican correlaciones inter-variables relevantes entre `density`–`fixed acidity` (0.68) y `alcohol`–`density` (-0.49).

F. Análisis y Manejo de Valores Atípicos

1) Detección mediante IQR: Para evitar *data leakage*, el split estratificado se realizó previamente a la detección de outliers. Los límites IQR se calcularon exclusivamente sobre el conjunto de entrenamiento (800 muestras) y luego se aplicaron a los tres subconjuntos. Se aplicó el método del Rango Intercuartílico (IQR) para identificar observaciones fuera del rango esperado. Un valor x se considera atípico si:

$$x < Q_1 - 1.5 \cdot IQR \quad \text{o} \quad x > Q_3 + 1.5 \cdot IQR \tag{2}$$

donde $IQR = Q_3 - Q_1$. Los resultados, visualizados en la Fig. 5, muestran que `residual sugar` concentra el mayor número de valores atípicos con 72 casos (9.00% del total de train), seguido por `chlorides` con 49 (6.12%) y `fixed acidity` y `sulphates` con 33 (4.12%) cada una. En el extremo opuesto, `citric acid` presenta apenas 1 caso (0.12%) y `volatile acidity` 8 (1.00%). Estos valores concuerdan con las asimetrías observadas en los histogramas.

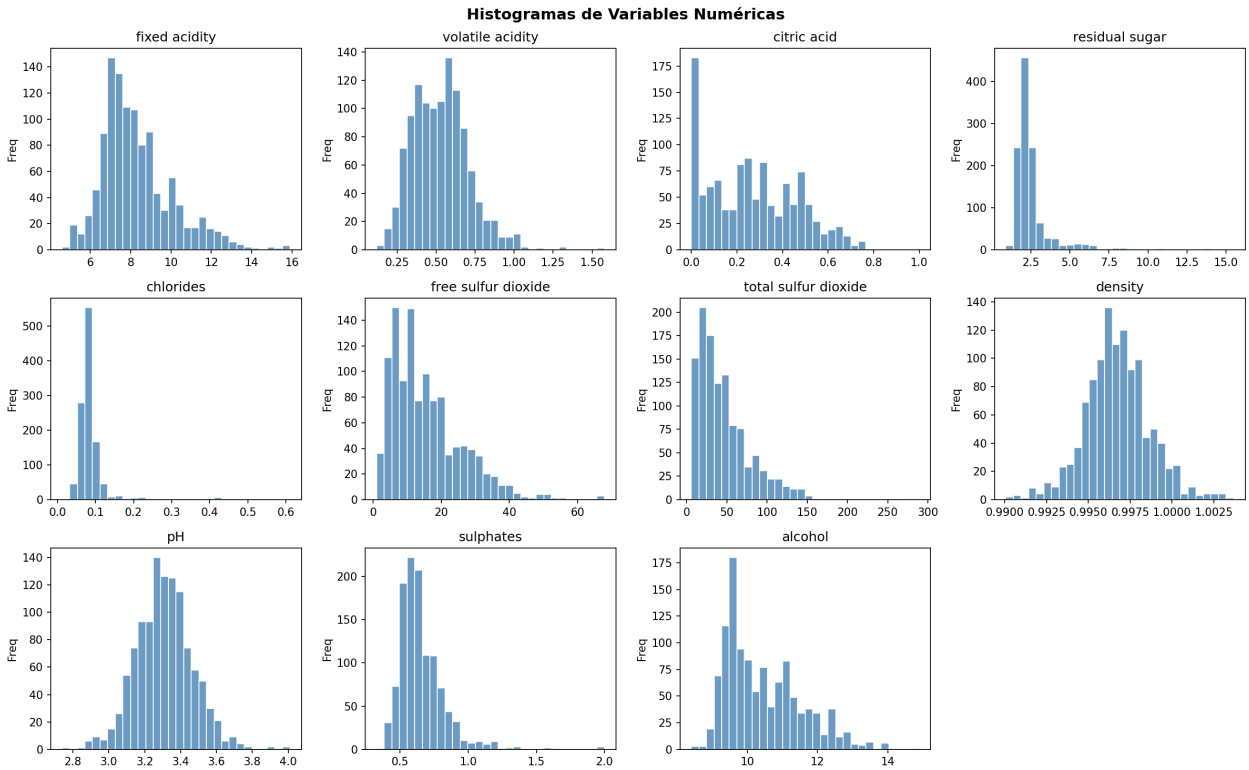

Fig. 2: Histogramas de las 11 variables numéricas. Se observan distribuciones marcadamente asimétricas en `residual sugar`, `chlorides` y `total sulfur dioxide`, con colas extensas hacia valores altos.

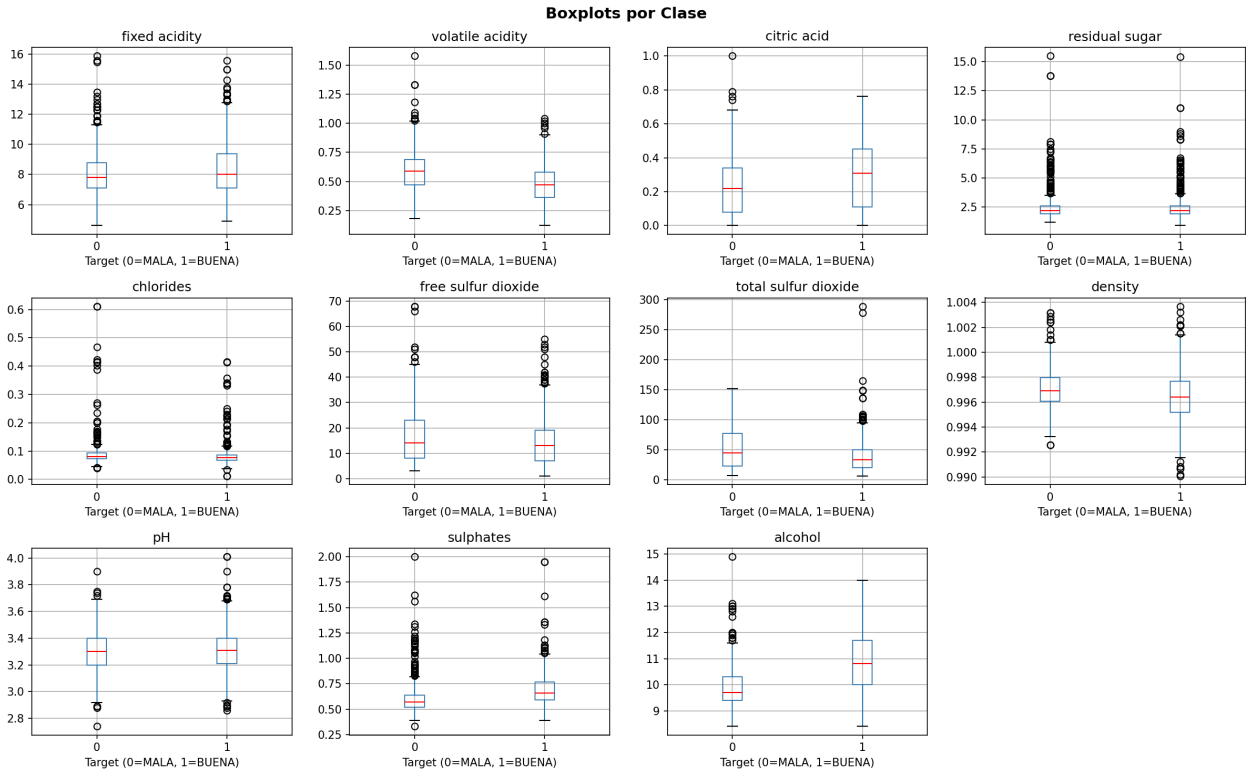

Fig. 3: Boxplots de las 11 variables segmentados por clase. `alcohol`, `sulphates` y `volatile acidity` muestran las diferencias más marcadas entre vinos BUENOS y MALOS.

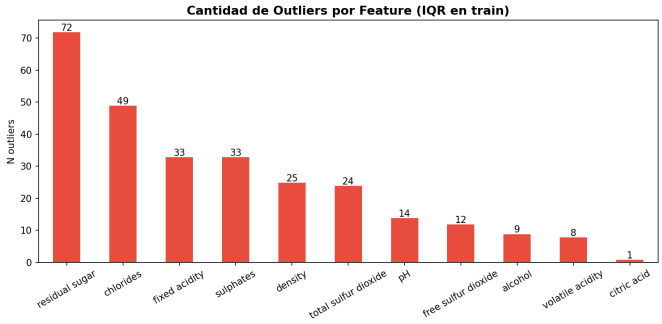

Fig. 5: Cantidad de outliers por variable según el método IQR aplicado sobre el conjunto de entrenamiento. `residual sugar` (72) y `chlorides` (49) son las variables más afectadas, mientras que `citric acid` es prácticamente libre de valores atípicos.

2) Estrategia de Manejo: Winzorización: Dado que los datos corresponden a mediciones físico-químicas reales de vinos, los valores extremos son físicamente posibles: un vino con azúcar residual de 15 g/L o cloruros de 0.6 g/L puede existir. Eliminar estas filas reduciría el tamaño del dataset y podría sesgar el modelo al excluir casos válidos de la distribución real. Por estas razones se optó por **winzorización (capping)**: los valores por encima del límite superior IQR se recortan a dicho límite, y los inferiores al límite inferior de igual forma. Esto preserva las 1,143 instancias sin introducir datos artificiales.

La Fig. 6 ilustra el efecto sobre las tres variables más afectadas. Para `residual sugar`, el rango se redujo de [0.9, 15.5] a [0.85, 3.65] g/L, eliminando la cola larga. `chlorides` pasó de un máximo de 0.61 a 0.12 g/L. `fixed acidity` redujo su máximo de 15.9 a 12.35 g/L. En todos los casos, la caja del boxplot se mantiene intacta y solo se eliminan los puntos extremos.

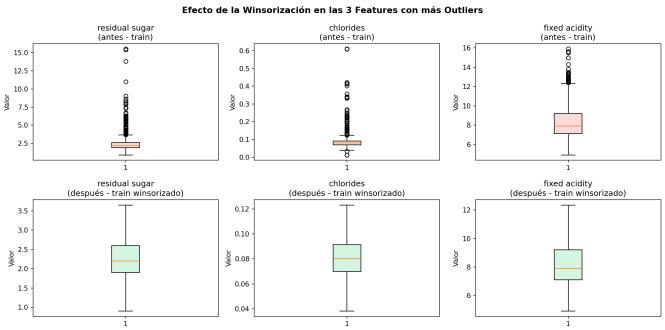

Fig. 6: Efecto de la winzorización en `residual sugar`, `chlorides` y `fixed acidity`. Las filas superiores muestran la distribución original con outliers en train; las inferiores, tras aplicar capping al límite IQR. La estructura central de cada variable se preserva.

3) Comparación de Estrategias: Para fundamentar la elección de la winzorización sobre la eliminación de filas, se entrenó un modelo idéntico (LR=0.001, batch=64, epochs=100) sobre dos versiones del dataset, evaluando el desempeño en el conjunto de prueba:

- **Estrategia A — Winzorización (1.5×IQR):** train=800, val=171. Sin eliminar instancias.
- **Estrategia B — Eliminación de outliers extremos (3×IQR):** train=722, val=158. Se eliminan los valores que superan tres veces el IQR, umbral a partir del cual los casos son genuinamente atípicos (78 instancias de train y 13 de validación eliminadas).

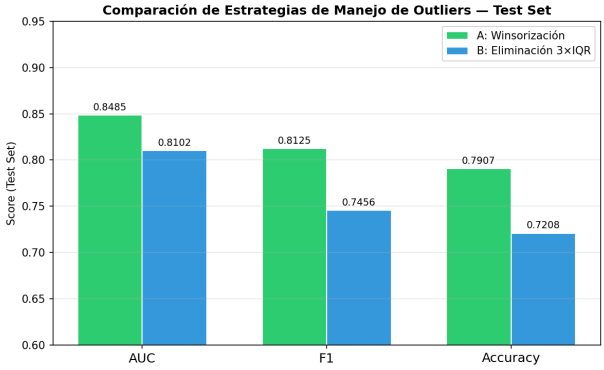

Fig. 7: Comparación de AUC, F1 y Accuracy en el conjunto de prueba bajo las dos estrategias de manejo de outliers. La winzorización obtiene resultados superiores, manteniendo además todas las instancias del dataset.

Como muestra la Fig. 7, la winzorización (Estrategia A) produce resultados superiores en el conjunto de prueba en todas las métricas: AUC 0.8485 vs. 0.8102, F1 0.8125 vs. 0.7456 y Accuracy 0.7907 vs. 0.7208. La eliminación con umbral 3×IQR reduce el tamaño del conjunto de entrenamiento sin ofrecer ganancia en desempeño, lo que confirma que la winzorización es la estrategia óptima para este problema.

III. Selección de Características

A. Justificación Matemática

La tarea establece un máximo de seis características. Se combinaron dos métodos complementarios para garantizar una selección robusta. Ambos criterios se calcularon exclusivamente sobre el conjunto de entrenamiento winsorizado, evitando así cualquier forma de *data leakage* metodológico:

1. Correlación de Pearson (valor absoluto): Cuantifica la relación lineal entre cada variable X_i y el *target* Y:

$$r(X_i, Y) = \frac{\mathrm{Cov}(X_i, Y)}{\sigma_{X_i} \cdot \sigma_Y} \tag{3}$$

2. Información Mutua (MI): Captura dependencias lineales y no lineales, definida como:

$$MI(X_i; Y) = \sum_y \sum_x p(x, y) \, \log \frac{p(x, y)}{p(x)\, p(y)} \tag{4}$$

Ambos métodos se normalizaron a rankings de 0 a 1 y se promedió el resultado. Este enfoque combinado es más robusto

que usar cualquiera de los dos de forma aislada: Pearson puede pasar por alto relaciones no lineales, mientras que MI puede ser inestable con muestras pequeñas. Adicionalmente, se verificó que ningún par de las características seleccionadas tuviera correlación mutua superior a 0.85. Ningún par superó dicho umbral, por lo que no fue necesario descartar ninguna variable por multicolinealidad.

B. Resultados de la Selección

La Fig. 8 presenta los tres rankings de forma visual. En la columna izquierda (Pearson), `alcohol` (0.4426) lidera ampliamente, seguido de `volatile acidity` (0.2983) y `total sulfur dioxide` (0.2773). La columna central (MI) confirma el liderazgo de `alcohol` (0.1050) pero reordena las siguientes posiciones: `sulphates` sube al segundo lugar (0.0873) y `total sulfur dioxide` al tercero (0.0610). El ranking combinado (columna derecha) refleja el consenso entre ambos criterios.

La Tabla II presenta los valores numéricos completos. Las seis características seleccionadas son: `alcohol`, `total sulfur dioxide`, `volatile acidity`, `sulphates`, `density` y `chlorides`. Las variables descartadas (`free sulfur dioxide`, `citric acid`, `fixed acidity`, `pH` y `residual sugar`) obtuvieron rankings consistentemente bajos en ambos criterios, y en el caso de `residual sugar`, MI prácticamente nula (0.0000).

TABLE II: Ranking combinado de características (Pearson + MI, sobre train)

Característica	$\lvert r \rvert$ Pearson	MI	Rank prom.
alcohol	0.4426	0.1050	1.0000
total sulfur dioxide	0.2773	0.0610	0.8182
volatile acidity	0.2983	0.0480	0.8182
sulphates	0.2770	0.0873	0.8182
density	0.1339	0.0376	0.5455
chlorides	0.1595	0.0209	0.4545
free sulfur dioxide	0.0813	0.0460	0.4545
citric acid	0.1281	0.0216	0.4091
fixed acidity	0.0842	0.0232	0.4091
pH	0.0601	0.0039	0.1818
residual sugar	0.0152	0.0000	0.0909

C. Diagramas de Dispersión

La Fig. 9 confirma visualmente el poder discriminativo de las seis características seleccionadas. En `alcohol`, los vinos BUENOS (verde) se concentran claramente por encima de 10.5%, mientras que los MALOS dominan en valores inferiores a 10%. `volatile acidity` muestra el patrón complementario: los MALOS se distribuyen hasta 1.0 g/L, mientras que los BUENOS rara vez superan 0.8 g/L. Para `sulphates`, la separación es menos limpia pero visible: los BUENOS tienen mayor densidad en el rango 0.6–0.9. `total sulfur dioxide`, `chlorides` y `density` muestran solapamiento considerable entre clases, lo que explica por qué el modelo final alcanza un AUC aproximado de 0.83 y no valores más altos: la frontera de decisión en estas variables no es nítida.

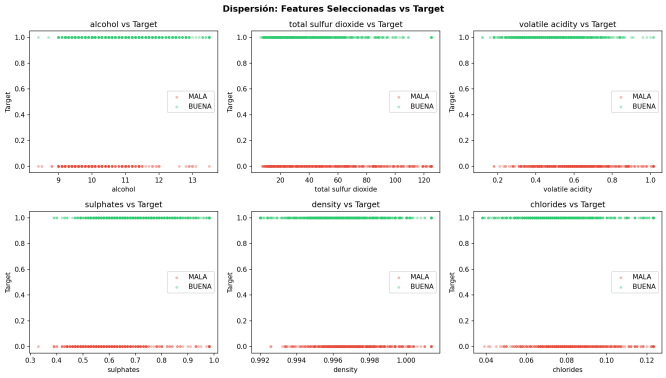

Fig. 9: Diagramas de dispersión de las seis características seleccionadas vs. *target*. `alcohol` y `volatile acidity` presentan la mayor separación entre clases. `total sulfur dioxide`, `chlorides` y `density` muestran solapamiento, lo cual es consistente con sus rankings intermedios.

IV. Preprocesamiento y División del Dataset

A. Stratified Sampling

Se dividió el dataset en tres subconjuntos aplicando *stratified sampling* **antes** del cálculo de outliers y de la selección de características, para evitar cualquier forma de *data leakage*:

- **Entrenamiento:** 800 muestras (70%) — 54.37% positivos
- **Validación:** 171 muestras (15%) — 54.39% positivos
- **Prueba:** 172 muestras (15%) — 54.07% positivos

El stratified sampling es la técnica adecuada para este problema por dos razones: primero, el dataset presenta un desbalance leve (54.33% vs. 45.67%) que un muestreo aleatorio puro podría amplificar en particiones pequeñas como la de validación (171 muestras); segundo, preservar la distribución original garantiza que las métricas calculadas sobre validación y prueba sean representativas del problema real y no de una distribución artificial.

B. Normalización

Se aplicó `StandardScaler` para transformar cada característica a media cero y desviación estándar uno:

$$x' = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}} \tag{5}$$

La normalización es indispensable para la regresión logística por dos motivos: garantiza que el gradiente no sea dominado por variables con rangos grandes (como `total sulfur dioxide` con rango [6, 289]) frente a variables con rangos pequeños (como `density` en [0.990, 1.004]), y acelera la convergencia del optimizador Adam. El escalador se ajustó únicamente con los datos de entrenamiento y se aplicó la misma transformación a validación y prueba, evitando así *data leakage*.

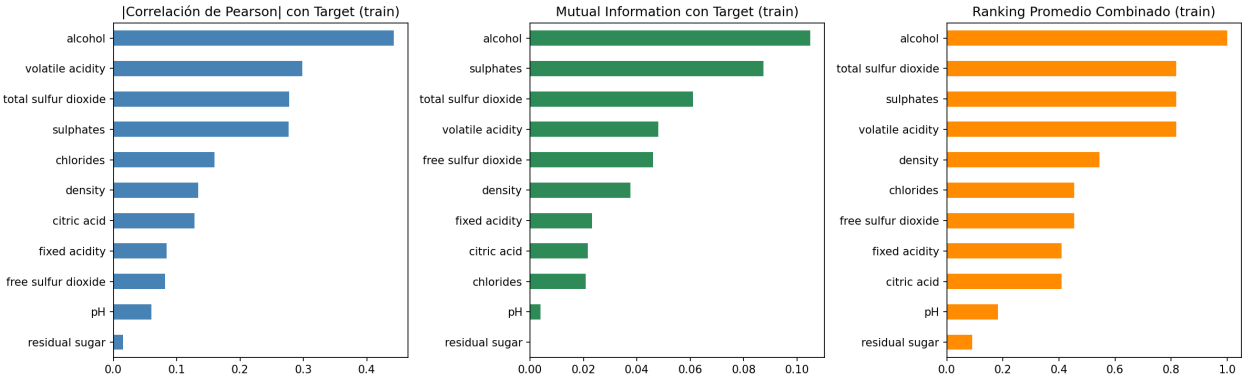

Fig. 8: Rankings de selección de características calculados sobre train. De izquierda a derecha: correlación de Pearson, información mutua, y ranking promedio combinado. `alcohol` lidera en los tres criterios. `pH` y `residual sugar` quedan consistentemente en las últimas posiciones.

V. Implementación del Modelo

A. Arquitectura

Se implementó la regresión logística como una red neuronal de capa única en PyTorch, heredando de `nn.Module`:

$$\hat{y} = \sigma\big(\mathbf{w}^\top \mathbf{x} + b\big) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}} \tag{6}$$

donde $\mathbf{x} \in \mathbb{R}^6$ es el vector de características normalizadas, $\mathbf{w} \in \mathbb{R}^6$ son los pesos aprendibles y b es el sesgo. La salida $\hat{y} \in (0, 1)$ representa la probabilidad estimada de calidad BUENA.

B. Función de Pérdida

Se utilizó *Binary Cross-Entropy* (BCE), función de pérdida canónica para clasificación binaria:

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^{N} \Big[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \Big] \tag{7}$$

BCE penaliza de forma cuadráticamente creciente las predicciones erróneas con alta confianza, lo que incentiva al modelo a ser calibrado, no solo correcto.

C. Optimizador

Se empleó Adam (*Adaptive Moment Estimation*) [4], que adapta la tasa de aprendizaje por parámetro utilizando estimaciones del primer y segundo momento del gradiente. Es preferible a SGD básico por su mayor velocidad de convergencia y menor sensibilidad al *learning rate* inicial, especialmente importante dado que se exploran diez configuraciones distintas.

VI. Experimentos y Resultados

A. Configuraciones de Hiperparámetros

Se ejecutaron diez entrenamientos variando *learning rate* (LR), *batch size* y *epochs*. La Tabla III presenta los resultados completos en el conjunto de validación. Se registra además la época de mejor val loss (*Best Val Epoch*) para identificar el punto óptimo de convergencia de cada experimento.

B. Análisis de Curvas de Pérdida

Las curvas de la Fig. 10 permiten identificar patrones de convergencia distintos según la configuración.

Experimentos 1–3 (LR=0.01, 50 epochs): Convergen rápidamente en las primeras 10 épocas. La *validation loss* cae por debajo de la *training loss* desde el inicio y se estabiliza cerca de 0.479–0.480, mientras la training loss se mantiene alrededor de 0.499–0.518. Este comportamiento es explicable: con batch size pequeño, el gradiente estocástico introduce ruido que eleva artificialmente la training loss respecto a la validation loss. No constituye overfitting.

Experimentos 4–6 (LR=0.001, 100 epochs): El Exp 4 (batch=32) muestra descenso progresivo y estable, alcanzando su mejor val loss en la época 97. Los Exp 5 y 6 (batch=64 y 128) presentan convergencia más lenta, sin alcanzar la meseta al final de las 100 épocas (Best Val Epoch=100), lo que indica que se beneficiarían de más iteraciones.

Experimentos 7–9: El Exp 7 (LR=0.005, batch=32) converge muy rápidamente en las primeras 30 épocas y se estabiliza. El Exp 9 (LR=0.0005, batch=32, 200 epochs) muestra descenso gradual y alcanza su óptimo en la época 129, con train loss=0.5146 y val loss=0.4784 al finalizar.

Experimento 10 (LR=0.0001, 300 epochs): Ambas curvas descienden de forma continua durante las 300 épocas sin llegar a una meseta clara, con la training loss en 0.5578 y la validation loss en 0.5331 al final (Best Val Epoch=300). Con un LR tan bajo el modelo requiere muchas más iteraciones para converger, configurando un caso de **underfitting por hiperparámetros inadecuados**.

C. Comparación de Métricas

La Fig. 11 presenta la evolución de las cinco métricas a través de los diez experimentos. Se observa que el AUC (púrpura) se mantiene estable entre 0.849 y 0.854 para los experimentos 1–9, evidenciando que la capacidad discriminativa del modelo es robusta a variaciones moderadas de hiperparámetros. El Exp 10 presenta valores inferiores en todas las métricas, reflejo directo del underfitting ya descrito.

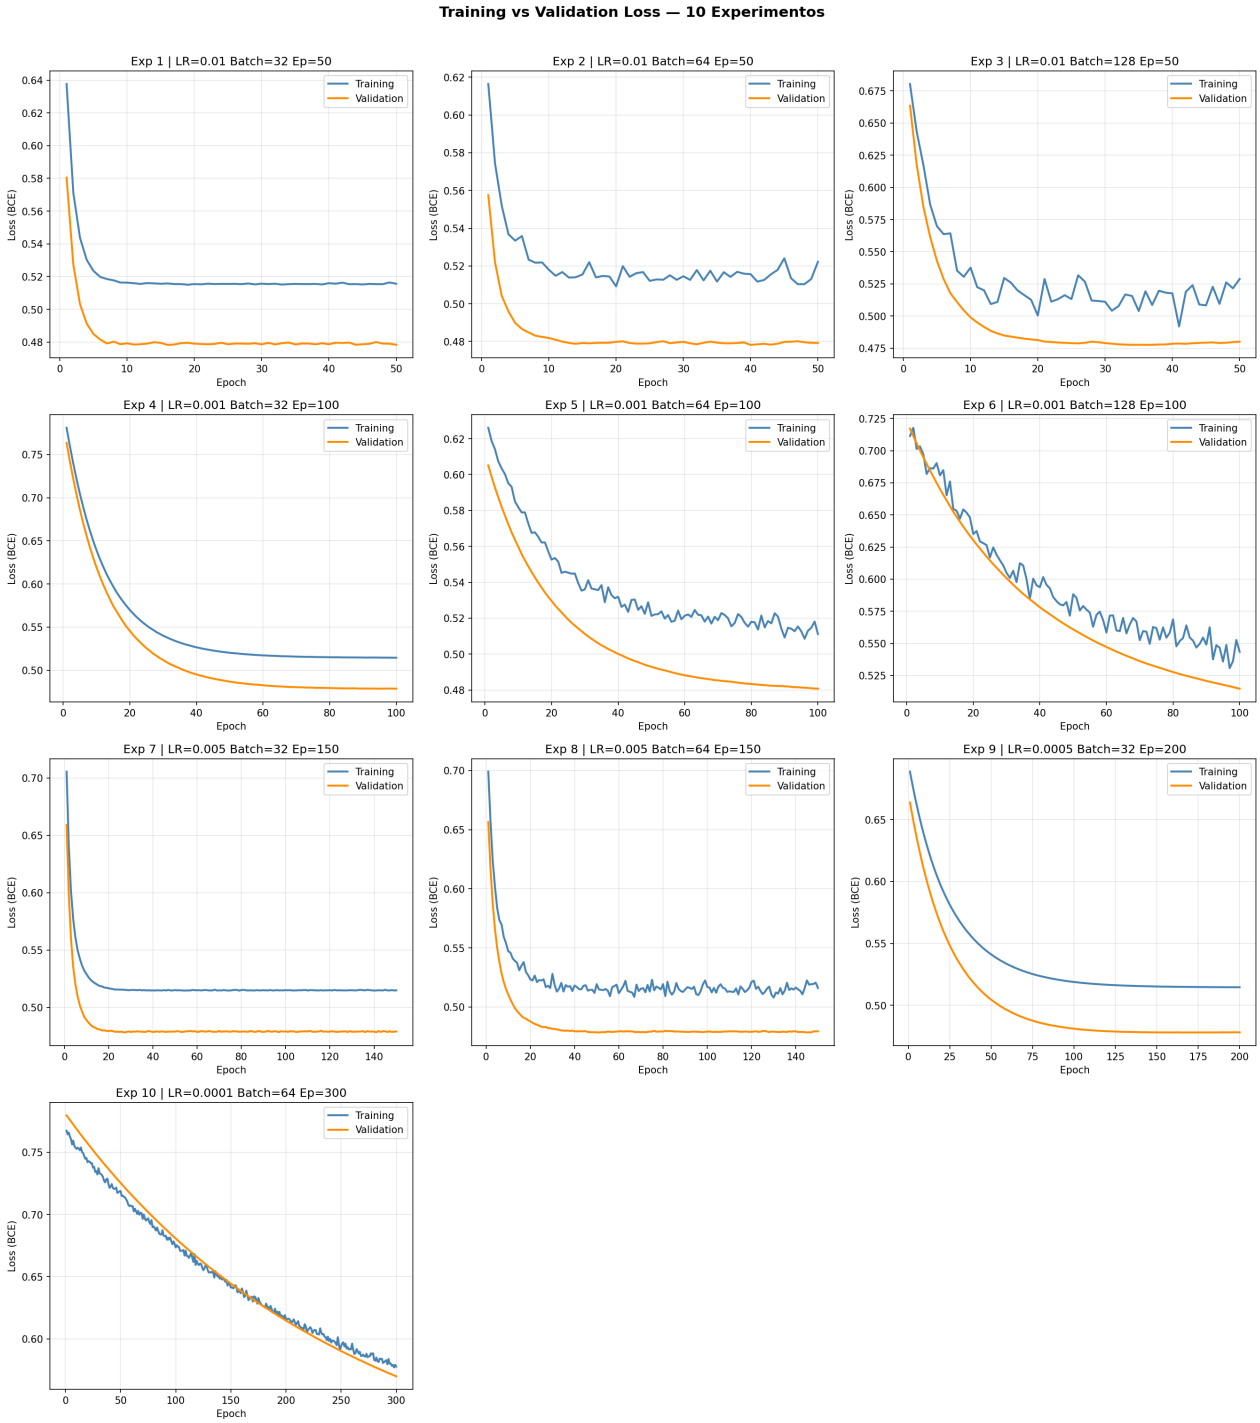

Fig. 10: Curvas de Training vs. Validation Loss para los 10 experimentos. Los experimentos 1–9 convergen correctamente. El Exp 10 (LR=0.0001) aún no ha alcanzado la meseta tras 300 épocas, indicando underfitting por tasa de aprendizaje insuficiente.

TABLE III: Comparativa de los 10 experimentos — métricas en validación

Exp	LR	Batch	Epochs	Best Ep.	Train Loss	Val Loss	Overfit	Acc	Prec	Recall	F1	AUC
1	0.0100	32	50	10	0.5161	0.4789	No	0.8012	0.8315	0.7957	0.8132	0.8514
2	0.0100	64	50	49	0.5178	0.4786	No	0.7895	0.8132	0.7957	0.8043	0.8526
3	0.0100	128	50	35	0.4995	0.4796	No	0.7778	0.8022	0.7849	0.7935	0.8521
4	0.0010	32	100	97	0.5152	0.4790	No	0.7719	0.7935	0.7849	0.7892	0.8537
5	0.0010	64	100	100	0.5286	0.4928	No	0.7778	0.7778	0.8280	0.8021	0.8490
6	0.0010	128	100	100	0.5393	0.5146	No	0.7778	0.7778	0.8280	0.8021	0.8507
7	0.0050	32	150	135	0.5150	0.4791	No	0.7895	0.8202	0.7849	0.8022	0.8514
8	0.0050	64	150	143	0.5205	0.4789	No	0.7836	0.8111	0.7849	0.7978	0.8518
gray!20 9	0.0005	32	200	129	0.5146	0.4784	No	0.7778	0.8022	0.7849	0.7935	**0.8528**
10	0.0001	64	300	300	0.5578	0.5331	No	0.7485	0.8049	0.7097	0.7543	0.8235

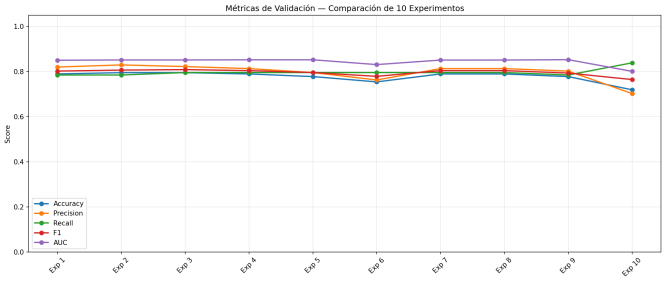

Fig. 11: Comparación de métricas de validación. Los experimentos 1–9 mantienen AUC estable (≈0.851) y métricas cercanas entre sí. El Exp 10 presenta valores inferiores producto del underfitting.

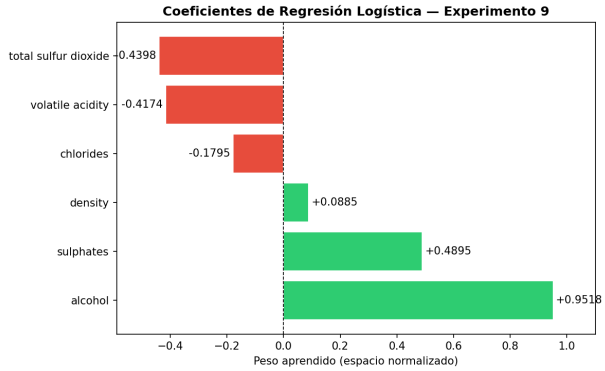

Fig. 12: Coeficientes aprendidos por el modelo final (Exp 9). Verde indica efecto positivo sobre la probabilidad de calidad BUENA; rojo, efecto negativo.

VII. Análisis del Modelo Final

A. Selección del Mejor Modelo

El **Experimento 9** (LR=0.0005, batch=32, epochs=200) fue seleccionado como modelo final al obtener el mayor AUC en validación (0.8528). El AUC es la métrica de selección más adecuada para este problema por dos razones: es independiente del umbral de decisión, permitiendo evaluar la capacidad discriminativa global del modelo, y es más robusta que el accuracy cuando existe desbalance de clases [2].

B. Pesos Aprendidos del Modelo Final

Los coeficientes $\mathbf{w}$ aprendidos por la capa lineal son directamente interpretables como los pesos de la regresión logística. Dado que todas las características están normalizadas a la misma escala, los pesos son comparables entre sí: un valor positivo indica que la variable aumenta la probabilidad de calidad BUENA, y un valor negativo que la reduce.

La Fig. 12 confirma cuantitativamente las observaciones del EDA. `alcohol` obtiene el peso positivo más alto (+0.9518), siendo la variable que más incrementa la probabilidad de BUENA al aumentar. `sulphates` contribuye positivamente (+0.4895), mientras que `density` tiene un efecto positivo menor (+0.0885). `total sulfur dioxide` presenta el peso negativo de mayor magnitud (-0.4398), seguido de `volatile acidity` (-0.4174): mayor acidez volátil reduce significativamente la probabilidad de calidad BUENA, consistente con su correlación negativa (-0.33) con el *target*. `chlorides` muestra el menor peso en valor absoluto (-0.1795), lo que sugiere que su inclusión aporta información marginal aunque no nula.

C. Significancia Estadística de la Selección

Los tres experimentos con mayor AUC en validación son el Exp 9 (0.8528), Exp 2 (0.8526) y Exp 4 (0.8537). Para determinar si las diferencias son estadísticamente significativas, se calculó el error estándar del AUC mediante el método de Hanley & McNeil [6]:

$$SE(\widehat{AUC}) = \sqrt{\frac{A + B + C}{n_+ \cdot n_-}} \tag{8}$$

donde los términos del numerador se definen como:

$$A = AUC(1 - AUC)$$
$$B = (n_+ - 1)\left(\frac{AUC}{2 - AUC} - AUC^2\right)$$
$$C = (n_- - 1)\left(\frac{2\,AUC^2}{1 + AUC} - AUC^2\right)$$

con n_+ y n_- siendo el número de positivos y negativos en validación (93 y 78 respectivamente). Los intervalos de confianza al 95% resultantes son: Exp 9: IC95% = [0.7962, 0.9094] (SE=0.0289); Exp 2: IC95% = [0.7959, 0.9093] (SE=0.0289); Exp 4: IC95% = [0.7972, 0.9102] (SE=0.0288). Los intervalos se solapan completamente, indicando que la diferencia **no es estadísticamente significativa**. El Exp 9 se selecciona como modelo final por ser el punto máximo observado, reconociendo que cualquiera de los tres hubiera sido una elección igualmente válida.

D. Evaluación en el Conjunto de Prueba

TABLE IV: Métricas del Experimento 9 — validación vs. prueba

Métrica	Validación	Prueba
Accuracy	0.7778	0.7500
Precision	0.8022	0.7778
Recall	0.7849	0.7527
F1-Score	0.7935	0.7650
AUC	0.8528	0.8277

La Tabla IV muestra una caída moderada de todos los indicadores al pasar de validación a prueba. El AUC disminuye de 0.8528 a 0.8277 ($\Delta = 0.025$), el F1 de 0.7935 a 0.7650 ($\Delta = 0.029$) y el accuracy de 0.7778 a 0.7500 ($\Delta = 0.028$). Estas diferencias son pequeñas y esperables dado el tamaño del conjunto de prueba (172 muestras), y no constituyen evidencia de sobreajuste. El AUC de 0.8277 en prueba confirma que el modelo generaliza bien a datos no vistos.

E. Matriz de Confusión

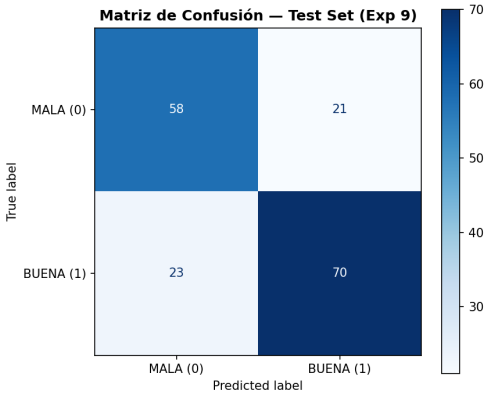

Fig. 13: Matriz de confusión del modelo final (Exp 9) sobre el conjunto de prueba (172 instancias). TN=58, FP=21, FN=23, TP=70.

La matriz de confusión (Fig. 13) sobre las 172 instancias de prueba muestra:

- **Verdaderos Negativos (TN = 58):** El modelo clasificó correctamente 58 vinos MALOS, representando una tasa de especificidad de $58/79 = 73.4\%$.
- **Falsos Positivos (FP = 21):** 21 vinos MALOS fueron incorrectamente clasificados como BUENOS. Corresponde a una tasa de error Tipo I de 26.6%.
- **Falsos Negativos (FN = 23):** 23 vinos BUENOS fueron clasificados como MALOS. Tasa de error Tipo II de 24.7%.
- **Verdaderos Positivos (TP = 70):** El modelo identificó correctamente 70 vinos de calidad BUENA, con una sensibilidad (recall) de $70/93 = 75.3\%$.

La simetría aproximada entre FP (21) y FN (23) indica que el modelo no presenta sesgo sistemático hacia ninguna clase. La precision de 0.7778 implica que cuando el modelo predice BUENO, acierta casi el 78% de las veces, valor adecuado para una aplicación de control de calidad donde los costos de FP y FN son similares.

VIII. Discusión

Los resultados confirman que las propiedades físico-químicas del vino contienen información suficiente para clasificar su calidad con AUC superior a 0.82. El `alcohol` emerge consistentemente como el predictor más importante, lo cual es consistente con la literatura enológica: vinos con mayor graduación alcóholica tienden a tener mayor cuerpo y complejidad [3]. La `volatile acidity` negativa refuerza la idea de que el ácido acético en exceso deteriora la calidad organoléptica.

La estabilidad de los resultados en los experimentos 1–9 sugiere que la regresión logística ha convergido a un óptimo global bien definido: la función de pérdida BCE es convexa

para modelos lineales, garantizando que distintas configuraciones de hiperparámetros lleguen al mismo mínimo si se dan las condiciones de convergencia. Esta propiedad diferencia la regresión logística de redes profundas donde múltiples mínimos locales hacen que los hiperparámetros impacten más significativamente el resultado final.

La principal limitación del modelo es su linealidad. Los diagramas de dispersión (Fig. 9) muestran considerable solapamiento entre clases en `density`, `chlorides` y `total sulfur dioxide`, que una frontera lineal no puede separar eficientemente. Modelos no lineales como *Gradient Boosting* o redes neuronales con capas ocultas podrían capturar estas interacciones y mejorar el AUC en prueba.

IX. Conclusiones

1) Se implementó exitosamente un modelo de regresión logística en PyTorch para clasificación binaria de calidad de vino, alcanzando un AUC de 0.8277 y F1-Score de 0.7650 en el conjunto de prueba.
2) La selección de las seis características más relevantes (`alcohol`, `total sulfur dioxide`, `volatile acidity`, `sulphates`, `density`, `chlorides`) se fundamentó matemáticamente con correlación de Pearson e información mutua calculadas sobre train, sin necesidad de descartar ninguna por multicolinealidad.
3) La winzorización fue la estrategia correcta para manejar outliers: preservó las 1,143 instancias y obtuvo mejores resultados en prueba (AUC +0.038, F1 +0.067) frente a la eliminación con umbral $3\times$IQR que descartó 78 instancias de entrenamiento.
4) El análisis de pesos confirmó que `alcohol` es el predictor positivo más influyente (+0.9518) y `total sulfur dioxide` el negativo más fuerte (-0.4398), seguido por `volatile acidity` (-0.4174), coherente con el EDA y con la literatura enológica.
5) El modelo es robusto a variaciones moderadas de hiperparámetros (experimentos 1–9 con AUC entre 0.849 y 0.854). El análisis de Hanley & McNeil confirma que las diferencias entre los tres mejores experimentos no son estadísticamente significativas dado el tamaño del conjunto de validación.
6) El único caso de bajo rendimiento (Exp 10, AUC=0.8235 en validación) corresponde a underfitting por LR excesivamente bajo (0.0001), cuya época de mejor val loss coincide con el final del entrenamiento (epoch 300), indicando que el modelo aún no había convergido.
7) La arquitectura lineal constituye la principal limitación: el solapamiento entre clases en varias features sugiere que modelos no lineales podrían mejorar la clasificación.
8) Como mejora metodológica, tanto la detección de outliers como la selección de características se realizaron exclusivamente sobre el conjunto de entrenamiento, eliminando el riesgo de *data leakage* en estas etapas del pipeline.

Agradecimientos

Los autores agradecen al Instituto Tecnológico de Costa Rica por los recursos y apoyo brindados para el desarrollo de este trabajo.

References

[1] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," *Advances in Neural Information Processing Systems*, vol. 32, 2019.

[2] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[3] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis, "Modeling wine preferences by data mining from physicochemical properties," *Decision Support Systems*, vol. 47, no. 4, pp. 547–553, 2009.

[4] D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2015.

[5] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Wiley-Interscience, 2006.

[6] J. A. Hanley and B. J. McNeil, "The meaning and use of the area under a receiver operating characteristic (ROC) curve," *Radiology*, vol. 143, no. 1, pp. 29–36, 1982.

[7] Kaggle, "Wine Quality Dataset," 2023. [Online]. Available: https://www.kaggle.com/datasets/yasserh/wine-quality-dataset